

Modelització probabilística en futbol internacional: el cas del Mundial 2026

Autor: Sergi Almendros Montoya

Tutor: Llorenç Badiella

1 Context i objectius

La modelització probabilística de resultats esportius constitueix un problema d'interès dins de l'estadística i l'anàlisi de dades. En el cas del futbol internacional, la predicció de resultats presenta dificultats específiques derivades de la variabilitat temporal en el rendiment de les seleccions i la dependència del context competitiu (fase de grups, eliminatòries, classificatoris o amistosos).

En competicions com la Copa del Món, l'estructura del torneig (que combina fase de grups i eliminatòries directes) introdueix dependència seqüencial entre partits i genera un espai combinatori complex que impedeix una avaluació analítica tancada de les probabilitats finals. En aquest context, resulta necessari combinar models estadístics de predicció de partits individuals amb tècniques de simulació per estimar probabilitats agregades del torneig.

L'objectiu principal d'aquest treball és desenvolupar un marc metodològic que permeti estimar probabilitats de resultats en futbol internacional mitjançant la combinació de:

- Un sistema de ràtings dinàmics ofensius i defensius.
- Un model probabilístic de gols basat en distribucions de Poissons.
- Un esquema de simulació Monte Carlo per estimar probabilitats de progressió i victòria final en la Copa del Món 2026.

De manera més específica, els objectius del treball són:

- Construir un sistema Elo ofensiu-defensiu que capturi l'evolució temporal de la força de les seleccions.
- Estimar probabilitats coherents de victòria, empat i derrota a partir.
- Simular l'estructura completa del Mundial 2026 per obtenir distribucions de guanyar aquesta competició.
- Analitzar la capacitat predictiva del model mitjançant validació retrospectiva.

2 Metodologia

La metodologia del treball es divideix en cinc blocs principals.

2.1 Construcció del dataset

En primer lloc, es construirà un dataset amb partits internacionals de seleccions nacionals des de l'any 2000 fins a l'actualitat. Per a cada partit es recopilarà la informació següent:

- Equip local
- Equip visitant
- Gols de l'equip local
- Gols de l'equip visitant
- Competició
- Ronda de la competició

Aquest conjunt de dades servirà com a base per a la construcció dels rànings i la posterior modelització probabilística.

2.2 Model ELO ofensiu-defensiu dinàmic

Seguidament, s'implementarà un model Elo ofensiu-defensiu derivat del model Elo tradicional. A diferència del model clàssic, que assigna un únic valor de força a cada equip, en aquest treball cada selecció disposarà de dos rànings diferenciats:

- Ràting ofensiu, que reflecteix la capacitat de generar gols.
- Ràting defensiu, que reflecteix la capacitat de limitar els gols del rival.

Aquesta descomposició permet capturar millor les característiques específiques de cada equip, com ara seleccions amb un atac potent però una defensa feble.

El model serà dinàmic, ja que els rànings s'actualitzaran de manera seqüencial després de cada partit, incorporant informació sobre la importància competitiva i la recència dels enfrontaments.

2.3 Model Poisson amb ajust Dixon-Coles

Un cop estimats els rànings, els gols de cada partit es modelaran mitjançant distribucions de Poisson:

$$G_1 \sim \text{Poisson}(\lambda_1)$$

$$G_2 \sim \text{Poisson}(\lambda_2)$$

En aquest context, els paràmetres λ_1 i λ_2 representen el nombre esperat de gols que s'espera que marqui cada equip, condicionat a la informació prèvia disponible, principalment els rànings ofensius i defensius.

A partir d'aquestes intensitats s'estimarà la distribució de marcadors possibles i, en conseqüència, les probabilitats de:

- Victòria equip 1
- Empat
- Victòria equip 2

Per millorar l'ajust en marcadors baixos s'incorporarà una correcció tipus Dixon-Coles.

2.4 Simulació Monte Carlo del Mundial 2026

Un cop estimades les probabilitats de cada partit, es desenvoluparà una simulació Monte Carlo del Mundial 2026. Es replicarà l'estructura oficial del torneig, incloent fase de grups i rondes eliminatòries, aplicant les normes oficials de classificació i criteris de desempat.

La competició es simularà un nombre elevat de vegades (p. ex. 100.000 simulacions), i la probabilitat que una selecció i guanyi el torneig s'estimarà com:

$$P(i) = \frac{\text{Nombre de victòries del torneig per a } i}{\text{Nombre total de simulacions}}$$

2.5 Validació i anàlisi

Per validar el model es realitzarà un procés de backtesting sobre competicions anteriors. El model estimarà probabilitats per a partits ja disputats, i aquestes es compararan amb els resultats reals.

S'analitzarà:

- La capacitat del model per identificar correctament el resultat més probable.
- L'error mitjà entre les probabilitats estimades i els resultats observats.
- La comparació amb prediccions de cases d'apostes o models d'experts.

3 Bibliografia

References

- [1] M. J. Dixon and S. G. Coles, "Modelling association football scores and inefficiencies in the football betting market," *Journal of the Royal Statistical Society: Series C (Applied Statistics)*, vol. 46, no. 2, pp. 265–280, 1997. doi: 10.1111/1467-9876.00065.
- [2] R. Gásquez and V. Royuela, "The Determinants of International Football Success: A Panel Data Analysis of the Elo Rating," *Social Science Quarterly*, vol. 97, no. 2, pp. 125–141, 2016. doi: 10.1111/ssqu.12262.
- [3] K. F. Sellers, S. Borle, and G. Shmueli, "The COM–Poisson model for count data: A survey of methods and applications," *Applied Stochastic Models in Business and Industry*, vol. 28, no. 2, pp. 104–116, 2012. doi: 10.1002/asmb.918.