



Treball Final de Grau

Modelització probabilística en futbol internacional: el cas del Mundial 2026

Autor: Sergi Almendros Montoya

Supervisor: Llorenç Badiella Busquets

Grau en Matemàtica Computacional i Analítica de Dades

19 de juny de 2026

Índex

1	Introducció	2
2	Dades i processament	3
2.1	Origen del conjunt de dades	3
2.2	Variabls derivades	3
2.3	Preprocesament	3
3	Marc Metodològic	4
3.1	El model ELO clàssic	4
3.1.1	Probabilitat esperada de victòria	4
3.1.2	Actualització dinàmica dels rànings	5
3.2	Limitacions del model ELO clàssic en futbol	5
3.3	Proposta: Model ELO-Poisson amb rànings ofensius i defensius	6
3.3.1	El model lineal generalitzat de Poisson	6
3.3.2	Rànings ofensius i defensius	7
3.3.3	ELO de confederació i efecte de propagació	8
3.3.4	Normalització intra-confederació	9
3.3.5	Estimació dels paràmetres del model	10
4	Validació del model	12
4.1	Estratègia de validació temporal	12
4.2	Mètriques de calibració probabilística	12
4.2.1	Brier Score	12
4.2.2	Log-loss	13
4.2.3	Ranked Probability Score	13
4.2.4	Reliability diagram i Expected Calibration Error	13
4.3	Comparativa amb models de referència	14
4.4	Anàlisi de convergència de l'algorisme iteratiu	16
4.5	Interpretació dels coeficients estimats	17
5	Simulació de la Copa del Món 2026	19
5.1	Estructura del torneig	19
5.2	Simulació d'un partit individual	19
5.3	Simulació d'una edició del torneig	20
5.4	Mètode de Monte Carlo	21
6	Resultats	22
6.1	Probabilitats per fase del torneig	22
6.2	Anàlisi per confederació	23
6.3	Evolució dels rànings	23
6.4	Comparativa amb el mercat d'apostes	24
6.4.1	Conversió de quotes a probabilitats	24
6.4.2	Comparativa	24
6.4.3	Interpretació	25
7	Conclusions	26
A	Repositori de codi	27
B	Verificació del conjunt de dades	28
C	Generació quadre fase eliminatòria Copa del Món	29

D Comparació dels resultants de la simulació amb altres models

30

Abstract

[ENG] This paper develops a probabilistic model for international soccer with the goal of estimating each national team's probability of winning the 2026 World Cup. The proposed model extends the classic ELO rating system in three directions: it decomposes each team's strength into an offensive and a defensive component, models the goals in each match as two independent Poisson distributions using a generalized linear model (GLM), and incorporates a dynamic confederation rating with intercontinental propagation that makes teams from different confederations comparable. The model's parameters are jointly estimated with an iterative algorithm inspired by the Expectation-Maximization procedure, using a dataset of 21127 international matches played between 2000 and 2026. On a time-varying validation set (2023–2026), the model consistently outperforms three benchmark models of increasing complexity (Brier Score 0.508, log-loss 0.865, RPS 0.167, ECE 0.041). Finally, the 2026 World Cup is simulated 100000 times using the Monte Carlo method, identifying Spain (17.6%), England (13.1%), and Brazil (10.8%) as the top title contenders, in notable agreement with the implied odds of the betting market.

Resum

[CAT] Aquest treball desenvolupa un model probabilístic per al futbol internacional de seleccions amb l'objectiu d'estimar la probabilitat de cada selecció de guanyar la Copa del Món de 2026. El model proposat amplia el sistema de ràtings ELO clàssic en tres direccions: descompon la força de cada selecció en una component ofensiva i una de defensiva, modela els gols de cada partit com dues distribucions de Poisson independents mitjançant un model lineal generalitzat (GLM), i incorpora un ràting dinàmic de confederació amb propagació intercontinental que fa comparables les seleccions de confederacions diferents. Els paràmetres del model s'estimen conjuntament amb un algorisme iteratiu inspirat en el procediment Expectation–Maximization, a partir d'un conjunt de 21127 partits internacionals disputats entre 2000 i 2026. Sobre un conjunt de validació temporal(2023–2026), el model millora de manera consistent tres models de referència de complexitat creixent (Brier Score 0.508, log-loss 0.865, RPS 0.167, ECE 0.041). Finalment, la Copa del Món 2026 se simula 100000 vegades pel mètode de Monte Carlo, identificant Espanya (17.6%), Anglaterra (13.1%) i Brasil (10.8%) com els principals candidats al títol, en concordança notable amb les probabilitats implícites del mercat d'apostes.

Resumen

[ESP] Este trabajo desarrolla un modelo probabilístico para el fútbol internacional de selecciones con el objetivo de estimar la probabilidad de cada selección de ganar la Copa del Mundo de 2026. El modelo propuesto amplia el sistema de ratings ELO clásico en tres direcciones: descompone la fuerza de cada selección en una componente ofensiva y una de defensiva, modela los goles de cada partido como dos distribuciones de Poisson independientes mediante un modelo lineal generalizado (GLM), e incorpora un rating dinámico de confederación con propagación intercontinental que hace comparables los selecciones de confederaciones diferentes. Los parámetros del modelo se estimen conjuntamente con un algoritmo iterativo inspirado en el procedimiento Expectation–Maximization, a partir de un conjunto de 21127 partidos internacionales disputados entre 2000 y 2026. Sobre un conjunto de validación temporal(2023–2026), el modelo mejora de manera consistente tres modelos de referencia de complejidad creciente (Brier Score 0.508, log-loss 0.865, RPS 0.167, ECE 0.041). Finalmente, la Copa del Mundo 2026 se simula 100000 veces por el método de Monte Carlo, identificando España (17.6%), Inglaterra (13.1%) y Brasil (10.8%) como los principales candidatos en el título, en concordancia notable con los probabilidades implícitas del mercado de apuestas.

Paraules claus: Model probabilístic – Model ELO – Poisson GLM – Ràtings (ELOs) Ofensiu, Defensiu i Confederació – Monte Carlo simulació – Copa del Món 2026

1 Introducció

Aquest treball desenvolupa un model probabilístic per al futbol internacional de seleccions amb un objectiu concret: estimar les probabilitats de cada selecció de guanyar la Copa del Món de 2026 simulant 100000 vegades el torneig.

El futbol de seleccions presenta particularitats que el diferencien del futbol de clubs. Les seleccions juguen pocs partits a l'any, sovint contra rivals de la mateixa regió geogràfica, i el nivell competitiu de les diferents confederacions és notablement heterogeni. Aquestes característiques fan que els models pensats per a les competicions de clubs no siguin directament aplicables i motivin un enfocament específic.

El model proposat es construeix sobre el principi establert per Maher [1]: modelar els gols d'un partit de futbol com dues variables aleatòries independents que segueixen una distribució de Poisson, una per a l'equip local i una altra per al visitant. El repte principal, doncs, és com estimar els paràmetres λ_1 i λ_2 d'aquestes distribucions, que representen els gols esperats de cada equip.

La proposta d'aquest treball consisteix a modelar aquests paràmetres mitjançant un sistema de ràntings dinàmics inspirat en el sistema ELO [2], que descompon el rendiment de cada selecció en una component ofensiva i una defensiva, i que s'actualitzen a partir dels resultats observats. També, el model incorpora dues variables més: el nivell de la confederació a la qual pertany cada selecció (també és una variable dinàmica) i l'efecte de jugar com a local.

Els objectius específics del treball són els següents:

- Dissenyar un model per estimar els gols esperats de cada equip en un partit.
- Estimar els paràmetres del model a partir de l'històric de partits internacionals i validar-ne la capacitat predictiva.
- Simular la Copa del Món de 2026 mitjançant el mètode de Monte Carlo per obtenir les probabilitats de cada selecció a disputar les diferents fases del torneig.
- Contrastar les probabilitats estimades del model amb les del mercat d'apostes.

La memòria s'estructura en set seccions. La Secció 2 descriu les dades utilitzades i el seu processament. La Secció 3 presenta el marc metodològic, des del sistema ELO clàssic fins al model proposat. La Secció 4 valida el model i el compara amb alternatives més simples. La Secció 5 descriu la simulació de la Copa del Món i la Secció 6 presenta els resultats, incloent comparació amb el mercat d'apostes. Per acabar, la Secció 7 recull les conclusions.

Cal explicar que l'enfocament d'aquest treball és fonamentalment probabilístic: l'objectiu no és predir un marcador concret ni classificar el resultat d'un partit en una única categoria (victòria, empat o derrota), sinó estimar una distribució de probabilitat sobre tots els resultats possibles. Aquesta distinció és essencial, ja que en el futbol dos partits jugats en condicions idèntiques poden acabar de manera diferent. Un model probabilístic no pretén encertar sempre el resultat, sinó assignar a cada marcador una probabilitat que reflecteixi la seva freqüència real.

2 Dades i processament

2.1 Origen del conjunt de dades

Les dades utilitzades en aquest treball provenen del conjunt *International football results from 1872 to 2024*, disponible a la plataforma Kaggle [3]. La base de dades recull tots els partits oficials disputats entre seleccions nacionals masculines absolutes des del primer enfrontament documentat de la història (Escòcia–Anglaterra, 30 de novembre de 1872) fins a l’actualitat. El fitxer base, **results.csv**, conté un registre de 49.287 partits, cadascun amb les variables mostrades a continuació:

Variable	Descripció
date	Data del partit
home_team	Selecció local
away_team	Selecció visitant
home_score	Gols de l’equip local
away_score	Gols de l’equip visitant
tournament	Competició a la qual pertany el partit
city	Ciutat on s’ha disputat el partit
country	País on s’ha disputat el partit
neutral	Variable booleana de camp neutral

Taula 1: Variables disponibles al conjunt de dades original.

2.2 Variables derivades

A partir del conjunt original s’han generat variables addicionals necessàries per a l’aplicació del model proposat:

- **home_confederation, away_confederation**: confederació a la qual pertany cada selecció (UEFA, CONMEBOL, AFC, CAF, CONCACAF, OFC).
- **is_intercontinental**: variable booleana que indica si el partit es disputa entre seleccions de confederacions diferents.
- **competition**: variable categòrica que classifica cada partit segons la rellevància del torneig en cinc nivells: *World Cup*, *Continental Cup*, *Secondary Continental Cup*, *International Cup* i *Friendlies*.
- **stage**: fase del torneig (*Qualification*, *Tournament*, *Other*).

2.3 Preprocesament

S’han aplicat els filtres i transformacions següents:

1. Conversió de la variable **date** al format temporal estàndard per permetre l’ordenament cronològic dels partits i seleccionar els partits a partir de l’any 2000.
2. Eliminació de partits corresponents a seleccions actualment extintes o no reconegudes per la FIFA (com el cas de Groenlàndia).

El conjunt de treball final conté 21127 partits corresponents al període 2000–2026, sense valors faltants en cap variable. La fiabilitat del conjunt s’ha validat addicionalment mitjançant una verificació manual sobre una mostra aleatòria de partits (Annex B).

3 Marc Metodològic

3.1 El model ELO clàssic

El sistema ELO va ser desenvolupat per Elo [2] per a la Federació Internacional d'Escacs (FIDE) amb l'objectiu de mesurar l'habilitat relativa dels competidors en un entorn dinàmic. La idea fonamental és que cada jugador té associat un valor escalar R_A que representa la seva força, i que la probabilitat de victòria en un enfrontament depèn exclusivament de la diferència entre els ràtings dels dos jugadors.

3.1.1 Probabilitat esperada de victòria

El sistema ELO modela la probabilitat que el jugador A guanyi al jugador B a partir del model de Bradley-Terry [4]. Aquest model assigna a cada jugador una força positiva $q_i > 0$ i defineix la probabilitat de victòria com:

$$E_A = \frac{q_A}{q_A + q_B}$$

Per garantir que la força sigui sempre positiva Elo va proposar la parametrització exponencial:

$$q_i = 10^{R_i/400}$$

Substituint aquesta expressió a la probabilitat de Bradley-Terry i dividint numerador i denominador per $10^{R_A/400}$:

$$E_A = \frac{10^{R_A/400}}{10^{R_A/400} + 10^{R_B/400}} = \frac{1}{1 + 10^{(R_B - R_A)/400}}$$

A continuació, grafiquem aquesta distribució:




Figura 1: Resultat esperat segons el model ELO

Com es pot observar a la Figura 1, la funció resultant és estrictament creixent i simètrica respecte al punt d'equilibri i amb límits asimptòtics 0 i 1. Per construcció, $E_A + E_B = 1$, ja que es tracta d'una distribució de probabilitat sobre dos esdeveniments complementaris (quan un guanya, l'altre perd).

L'elecció del factor 400 a l'exponent és una convenció històrica adoptada per la FIDE.

3.1.2 Actualització dinàmica dels rànings

Una vegada disputada la partida, els rànings s'actualitzen en funció de la diferència entre el resultat observat $S_A \in \{0, 0.5, 1\}$ i l'esperat E_A :

$$R'_A = R_A + K(S_A - E_A), \quad R'_B = R_B + K(S_B - E_B)$$

on $K > 0$ és el factor d'actualització o *learning rate*. Com es pot observar, la magnitud de l'actualització depèn exclusivament de dos factors: $S_A - E_A$ i K , és a dir, de la diferència entre resultat esperat i observat (en el cas de produir-se un resultat poc probable, aquesta diferència serà major, per tant, l'actualització també); i del valor del *learning rate*, paràmetre que controla la velocitat d'actualització.

Una propietat estructural d'aquest model és la conservació de la massa total, en altres paraules, l'actualització ELO és un sistema de suma zero, per a qualsevol parell de jugadors A, B :

$$R'_A + R'_B = R_A + R_B$$

Es pot demostrar, sumant les dues equacions d'actualització:

$$\begin{aligned} R'_A + R'_B &= R_A + K(S_A - E_A) + R_B + K(S_B - E_B) \\ &= R_A + R_B + K[(S_A + S_B) - (E_A + E_B)] \end{aligned}$$

Per la definició del resultat, $S_A + S_B = 1$, i per la simetria del model de Bradley-Terry, $E_A + E_B = 1$. Per tant,

$$[(S_A + S_B) - (E_A + E_B)] = 0$$

i s'obté $R'_A + R'_B = R_A + R_B$.

Com a conseqüència directa, els punts que guanya un competidor són exactament els que perd el seu rival, i la massa total de ràting del sistema es conserva al llarg de les partides.

3.2 Limitacions del model ELO clàssic en futbol

El sistema ELO proporciona una estructura probabilística sòlida i, com es comprovarà a la validació (Secció 4), és un model competitiu per al pronòstic de resultats. La seva aplicació al futbol internacional, però, presenta quatre limitacions que motiven l'extensió proposada.

Primer de tot, el model clàssic només considera el resultat final del partit: victòria, empat o derrota. Partits amb dinàmiques molt diferents, però amb el mateix resultat final generen exactament el mateix impacte sobre els rànings. Una victòria per 1-0 i una per 5-0 aporten la mateixa informació al model, malgrat que la magnitud del resultat és clarament rellevant per estimar la força real dels equips.

Un altre aspecte a tenir en compte és que el model tracta la força de cada equip com una única magnitud escalar, sense distingir entre capacitat ofensiva i defensiva. En futbol, però, és habitual trobar equips amb perfils asimètrics: seleccions amb un gran potencial golejador però fràgils defensivament, o equips molt sòlids en defensa però poc ofensius. Una representació escalar no pot capturar aquesta dualitat.

També, el model assumeix que el resultat depèn exclusivament de la diferència de rànings. No obstant això, en el futbol el factor de jugar com a local influeix en el rendiment dels equips: el suport del públic i la reducció dels desplaçaments poden generar avantatges que el model clàssic no recull.

Finalment, el sistema ELO clàssic no distingeix el context competitiu en què s'obtenen els resultats. Un equip que acumula victòries dins d'una confederació de nivell baix pot assolir rànings similars als d'un equip que competeix habitualment contra rivals de més qualitat. Sense un mecanisme que calibri el nivell relatiu de cada confederació, els rànings perden comparabilitat a escala mundial.

Més enllà d'aquestes quatre limitacions, hi ha una raó de caràcter estructural que motiva aquesta nova formulació. El model ELO clàssic emet una probabilitat de resultat, però no una distribució sobre el nombre de gols. Aquesta distinció és decisiva per a aquest treball, ja que la simulació de la Copa del Món (Secció 5) requereix generar marcadors per construir les taules de grups amb els criteris de desempat de la FIFA (diferència de gols, gols a favor...) i per derivar probabilitats de resultat exacte. Així doncs, l'extensió proposada a la Secció 3.3 no només aborda cadascuna de les quatre limitacions anteriors, sinó que, alhora, afegeix la capacitat generativa de marcadors.

3.3 Proposta: Model ELO-Poisson amb ràtings ofensius i defensius

Per resoldre les limitacions descrites, el model assigna a cada selecció dos ràtings que evolucionen en el temps. D'una banda, el ràting ofensiu $OF_{i,t}$ quantifica la capacitat de l'equip per generar gols, de l'altra, el ràting defensiu $DF_{i,t}$ mesura la seva habilitat per evitar encaixar-ne.

3.3.1 El model lineal generalitzat de Poisson

El nombre de gols marcats per un equip en un partit és una variable aleatòria de comptatge $G \in \{0, 1, 2, \dots\}$. La distribució natural per modelar aquest tipus de variable és la Poisson:

$$P(G = k) = \frac{\lambda^k e^{-\lambda}}{k!}, \quad k = 0, 1, 2, \dots$$

on $\lambda > 0$ és l'únic paràmetre de la distribució. Per definició, $\mathbb{E}[G] = \lambda$, és per això que aquest paràmetre s'anomena habitualment gols esperats (*expected goals*).

Per aplicar aquesta distribució al cas d'un partit de futbol, modelitzem els gols dels dos equips com a variables de Poisson independents:

$$G_1 \sim \text{Poisson}(\lambda_1), \quad G_2 \sim \text{Poisson}(\lambda_2)$$

La hipòtesi d'independència és una simplificació que va introduir per primera vegada Maher [1], ja que produeix prediccions raonables i facilita l'estimació dels paràmetres, tot i que el rendiment d'un equip dins d'un partit afecta el del rival. Anys després, Dixon i Coles [5] van proposar una correcció explícita d'aquesta dependència, però, no s'ha aplicat a aquest treball.

Un model lineal generalitzat de Poisson connecta el paràmetre λ amb les variables mitjançant una funció d'enllaç g , de manera que $g(\lambda)$ s'expressa com a combinació lineal de les covariables. Per triar aquesta funció cal tenir en compte que $\lambda > 0$; per aquest motiu, la funció triada és el logaritme, de manera que $\lambda = e^\eta > 0$ per a qualsevol valor del predictor lineal $\eta \in \mathbb{R}$. Aquesta tria coincideix, a més, amb l'enllaç canònic de la Poisson dins de la família exponencial, fet que la justifica també des d'un punt de vista teòric.

Aleshores, amb aquesta informació, el model proposat:

$$\log(\lambda_1) = \alpha + \beta_1 \cdot OF_{1,t} + \beta_2 \cdot DF_{2,t} + \theta(\Gamma_{C_1,t} - \Gamma_{C_2,t}) + \gamma H \quad (1)$$

$$\log(\lambda_2) = \alpha + \beta_1 \cdot OF_{2,t} + \beta_2 \cdot DF_{1,t} + \theta(\Gamma_{C_2,t} - \Gamma_{C_1,t}) + \gamma A \quad (2)$$

on $OF_{i,t}$ i $DF_{i,t}$ són els ràtings ofensiu i defensiu de l'equip i en el moment t , Γ_{C_i} és el ràting de la confederació de l'equip i en el moment t , i $H = 1$ si l'equip 1 juga com a local en camp no neutral i $H = 0$ altrament, amb $A = -H$.

Cada terme respon a una de les limitacions identificades a la Secció 3.2: $\beta_1 OF$ i $\beta_2 DF$ capturen la dualitat ofensiva-defensiva (es preveu $\beta_1 > 0$ i $\beta_2 < 0$); $\theta(\Gamma_{C_1} - \Gamma_{C_2})$ recull la diferència entre confederacions, i γH modela l'efecte de la localitat.

A partir dels gols esperats λ_1 i λ_2 , les probabilitats dels tres resultats possibles es calculen sumant sobre les combinacions de gols que produeixen cada resultat:

$$\begin{aligned}
 P(\text{victòria local}) &= \sum_{g_1 > g_2} P(G_1 = g_1) \cdot P(G_2 = g_2) = \sum_{g_1 > g_2} \frac{\lambda_1^{g_1} e^{-\lambda_1}}{g_1!} \cdot \frac{\lambda_2^{g_2} e^{-\lambda_2}}{g_2!} \\
 P(\text{empat}) &= \sum_{g_1 = g_2} P(G_1 = g_1) \cdot P(G_2 = g_2) = \sum_{g_1 = g_2} \frac{\lambda_1^{g_1} e^{-\lambda_1}}{g_1!} \cdot \frac{\lambda_2^{g_2} e^{-\lambda_2}}{g_2!} \\
 P(\text{victòria visitant}) &= \sum_{g_1 < g_2} P(G_1 = g_1) \cdot P(G_2 = g_2) = \sum_{g_1 < g_2} \frac{\lambda_1^{g_1} e^{-\lambda_1}}{g_1!} \cdot \frac{\lambda_2^{g_2} e^{-\lambda_2}}{g_2!}
 \end{aligned}$$

En aquest treball, aquestes sumes es limiten a un màxim de 15 gols per equip (les probabilitats que un equip marqui més de 15 gols són negligibles).

3.3.2 Ràtings ofensius i defensius

A diferència del model ELO clàssic, on la força d'un competidor es descriu amb una única magnitud escalar, el model proposat assigna a cada selecció dos ràtings que evolucionen al llarg del temps: el ràting ofensiu $OF_{i,t}$, que mesura la capacitat de l'equip i per marcar gols, i el ràting defensiu $DF_{i,t}$, que mesura la capacitat per evitar gols en contra. Aquests dos ràtings constitueixen les principals variables del model presentat.

Com el model clàssic, després de cada partit, els ràtings s'actualitzen en funció de la diferència entre els gols reals i els gols esperats pel model (λ_1 i λ_2). Si denotem per G_1 i G_2 els gols observats, les actualitzacions per a l'equip 1 són:

$$\begin{aligned}
 OF_{1,t+1} &= OF_{1,t} + k \cdot G(n) \cdot (G_1 - \lambda_1) \\
 DF_{1,t+1} &= DF_{1,t} - k \cdot G(n) \cdot (G_2 - \lambda_2)
 \end{aligned}$$

i de manera simètrica per a l'equip 2:

$$\begin{aligned}
 OF_{2,t+1} &= OF_{2,t} + k \cdot G(n) \cdot (G_2 - \lambda_2) \\
 DF_{2,t+1} &= DF_{2,t} - k \cdot G(n) \cdot (G_1 - \lambda_1)
 \end{aligned}$$

La lògica és la següent: si un equip marca més gols dels esperats ($G_i > \lambda_i$), el residu és positiu i el seu ràting ofensiu augmenta; simètricament, el ràting defensiu del rival disminueix, ja que ha encaixat més gols dels previstos.

La funció $G(n)$ (ve de *World Football Elo Ratings* [6]), on $n = |G_1 - G_2|$ és la diferència de gols del partit, pondera l'actualització segons la magnitud del resultat:

$$G(n) = \begin{cases} 1 & \text{si } n < 2 \\ 1.5 & \text{si } n = 2 \\ \frac{n+11}{8} & \text{si } n > 2 \end{cases}$$

Per a resultats de diferència petita (0 o 1 gols de marge), el pes és igual a 1; per a una diferència de 2 gols el pes augmenta a 1.5, i a partir d'aquí creix linealment però amb suavitat. Així, un 5-0 actualitza més que un 2-0, però no tant com seria proporcional a la diferència de gols.

Finalment, el paràmetre k controla la velocitat global d'actualització del sistema. Un valor elevat fa que els ràtings s'adaptin ràpidament als resultats recents, mentre que un valor petit produeix una evolució més estable. En aquest treball, k no és una constant fixa sinó un valor que depèn de les característiques del partit. La seva modelització i optimització es detallen a la Secció 3.3.5.

3.3.3 ELO de confederació i efecte de propagació

A les equacions del model, s'ha introduït un ràting addicional a nivell de confederació, Γ_C , $\forall C \in \mathcal{C}$, on $\mathcal{C}$ denota el conjunt de les sis confederacions de la FIFA:

$$\mathcal{C} = \{\text{UEFA}, \text{CONMEBOL}, \text{AFC}, \text{CAF}, \text{CONCACAF}, \text{OFC}\}.$$

Aquest ràting captura el nivell competitiu global de la confederació. En aquest apartat es defineix com s'actualitza i com es propaga la informació intercontinental als ràtings individuals.

A diferència de OF i DF , que s'actualitzen després de cada partit, els ràtings de confederació només s'actualitzen quan l'enfrontament és intercontinental, és a dir, quan les dues seleccions implicades pertanyen a confederacions diferents ($C_1 \neq C_2$). Per definir l'actualització, introduïm el residu combinat del partit:

$$\Omega = (G_1 - \lambda_1) - (G_2 - \lambda_2)$$

que mesura el rendiment relatiu de l'equip 1 respecte de l'equip 2: $\Omega > 0$ indica que la confederació C_1 ha rendit per sobre del que el model preveia, i $\Omega < 0$ indica el contrari. Definim la magnitud de l'actualització intercontinental com:

$$\Delta = k \cdot G(n) \cdot k_\Gamma \cdot \Omega$$

on k_Γ és el *learning rate* específic de confederació, i k i $G(n)$ són els mateixos factors d'escala introduïts a la Secció 3.3.2. Aleshores, els ràtings de confederació s'actualitzen com:

$$\Gamma_{C_1,t+1} = \Gamma_{C_1,t} + \Delta, \quad \Gamma_{C_2,t+1} = \Gamma_{C_2,t} - \Delta$$

Addicionalment, la informació del partit intercontinental es propaga als ràtings individuals de tots els equips de les dues confederacions implicades. Per a tot equip $m \in C_1$:

$$OF_{m,t+1} = OF_{m,t} + \Delta, \quad DF_{m,t+1} = DF_{m,t} + \Delta$$

i per a tot equip $m \in C_2$:

$$OF_{m,t+1} = OF_{m,t} - \Delta, \quad DF_{m,t+1} = DF_{m,t} - \Delta$$

La idea d'aquesta propagació és la següent: si Brasil supera el que el model preveia davant d'un rival europeu, és raonable suposar que la resta de seleccions de la CONMEBOL són també una mica millors del que els seus ràtings actuals indicaven, ja que comparteixen un context competitiu similar. Simètricament, totes les seleccions de la UEFA reben un ajust a la baixa. D'aquesta manera, els duels intercontinentals propaguen informació cap a seleccions que no hi han participat directament.

Aquest ELO de confederació, i l'ajust que es fa és imprescindible, ja que, com podem observar a la Figura 2, està descompensat el nombre de partits entre continental i intercontinentals que es juguen.




Figura 2: Distribució del nombre de partits segons la variable `is_intercontinental`

3.3.4 Normalització intra-confederació

Tot i la introducció del ràting de confederació Γ_C , el sistema encara presenta una limitació subtil: els ràtings individuals $OF_{i,t}$ i $DF_{i,t}$ es poden inflar de manera no controlada per a seleccions que dominen sistemàticament la seva confederació. Això succeeix perquè $OF_{i,t}$ i $DF_{i,t}$ s'actualitzen després de tots els partits, mentre que Γ_C només s'actualitza en els intercontinentals. Una selecció que jugui majoritàriament dins de la seva confederació pot acumular un increment molt gran en els seus ràtings individuals sense que el ràting de confederació l'acompanyi al mateix ritme.

Considerem un equip que guanya consistentment dins d'una confederació amb una ràtio elevada de partits continentals respecte a intercontinentals. Per una banda, els seus residus $G_i - \lambda_i$ tendeixen a ser positius, fet que fa créixer $OF_{i,t}$ partit rere partit. Per altra banda, els seus rivals tendeixen a marcar-li menys gols dels previstos pel model, és a dir, els residus dels rivals són típicament negatius, fet que també fa créixer $DF_{i,t}$. Atès que la gran majoria dels seus partits són continentals, els escassos partits intercontinentals no generen prou informació perquè Γ_C corregeixi aquesta deriva a través del mecanisme de propagació. El resultat és una selecció amb ràtings individuals desproporcionadament alts respecte al seu rendiment real a escala global.

Per resoldre aquest problema, s'introdueix un pas de normalització anual. Sigui $\mathcal{T}_C$ el conjunt de seleccions pertanyents a la confederació C , i siguin $\overline{OF}_{C,t}$ i $\overline{DF}_{C,t}$ les mitjanes dels ràtings ofensiu i defensiu dins de C en el moment t :

$$\overline{OF}_{C,t} = \frac{1}{|\mathcal{T}_C|} \sum_{i \in \mathcal{T}_C} OF_{i,t}, \quad \overline{DF}_{C,t} = \frac{1}{|\mathcal{T}_C|} \sum_{i \in \mathcal{T}_C} DF_{i,t}.$$

Cada any natural, just abans de processar el primer partit de l'any nou, es resta la mitjana de la confederació a cada selecció membre:

$$OF_{i,t} \leftarrow OF_{i,t} - \overline{OF}_{C,t}, \quad DF_{i,t} \leftarrow DF_{i,t} - \overline{DF}_{C,t}, \quad \forall i \in \mathcal{T}_C, \forall C \in \mathcal{C}.$$

Aquesta operació transforma el significat dels ràtings individuals: després de la normalització, $OF_{i,t}$ i $DF_{i,t}$ no representen una força absoluta, sinó la desviació de la selecció i respecte a la mitjana de la

seva confederació. El nivell global de cada confederació queda íntegrament capturat pel ràting Γ_C , de manera que les dues components del model treballen sobre escales ben definides i no redundants: Γ_C captura la posició global de la confederació, mentre que OF i DF capturen la posició relativa de cada selecció dins d'ella.

3.3.5 Estimació dels paràmetres del model

El model proposat conté dos tipus de paràmetres que requereixen estimació: els coeficients del GLM, $\theta = (\alpha, \beta_1, \beta_2, \theta, \gamma)$, i els factors multiplicatius que configuren el *learning rate* k i k_Γ . Aquests valors s'estimen amb procediments diferents, però, degut a la interdependència entre els ràtings ELO i els paràmetres del GLM, s'integren amb un procediment inspirat en Expectation-Maximization (EM) proposat per Dempster, Laird i Rubin [7]:

Estimació dels paràmetres del GLM. Donats els ràtings $OF_{i,t}$, $DF_{i,t}$ i $\Gamma_{C,t}$, els coeficients del GLM s'estimen per màxima versemblança. A partir de la funció de massa de Poisson, la log-versemblança per a un conjunt de N partits (on per cada partit tenim 2 estimacions, la del local i la del visitant) és:

$$\ell(\theta) = \sum_{i=1}^N \sum_{j \in \{1,2\}} [g_{j,i} \log \lambda_{j,i} - \lambda_{j,i} - \log(g!)]$$

com g és constant respecte als paràmetres que estem estimant:

$$\ell(\theta) = \sum_{i=1}^N \sum_{j \in \{1,2\}} [g_{j,i} \log \lambda_{j,i} - \lambda_{j,i}] + \text{const.}$$

L'estimador $\hat{\theta}$ s'obté maximitzant aquesta funció.

Optimització del factor k . Com s'ha descrit a la Secció 3.3.2, el *learning rate* en aquest treball no s'ha fixat, sino que es calcula com un producte de factors multiplicatius que capturen el context de cada partit:

$$k = k_0 \cdot \prod_{j \in J} f_j$$

on k_0 és el valor base i f_j són factors associats a tres variables (presentades a la Secció 2.2) el caràcter intercontinental o continental del partit, la fase del torneig i la importància de la competició.

Per determinar els valors òptims d'aquests factors, s'ha implementat una cerca de graella (*grid search*) combinada amb validació creuada temporal. En cada iteració de la cerca, es fixa una combinació de factors, s'executa el model complet sobre el conjunt d'entrenament i s'avalua la qualitat de les prediccions sobre el conjunt de validació mitjançant la *Negative Log-Likelihood* (NLL):

$$\text{NLL} = \sum_{i=1}^N \sum_{j \in \{1,2\}} (\lambda_{j,i} - g_{j,i} \log(\lambda_{j,i}))$$

L'ús de validació temporal garanteix que el model s'entreni exclusivament amb dades anteriors a les que s'utilitzen per avaluar-lo, evitant així la filtració de dades (*data leakage*). Els valors òptims resultants es recullen a la Taula 2.

Factor	Valor
k_0 (base)	0.05
Intercontinental	1.20
Continental	1.00
Fase: classificació	1.20
Fase: torneig	1.20
Fase: altres	1.00
Copa del Món	2.50
Copa continental	2.00
Copa continental secundària	1.50
Copa internacional	1.00
Amistosos	1.00

Taula 2: Valors òptims dels factors multiplicatius de k obtinguts per *grid search* amb validació creuada temporal.

Per exemple, per a la final del Mundial entre seleccions de confederacions diferents:

$$k = 0.05 \cdot 1.20 \cdot 1.20 \cdot 2.50 = 0.18$$

mentre que per a un amistós continental:

$$k = 0.05 \cdot 1.00 \cdot 1.00 \cdot 1.00 = 0.05$$

També, aquest procés d'optimització ha servit per estimar el valor del *learning rate* de confederació k_Γ , introduït a la Secció 3.3.3, obtenint un valor de $k_\Gamma = 0.05$.

Algorisme iteratiu d'estimació conjunta. El model presenta una interdependència circular entre els ràntings i els paràmetres del GLM: els ràntings $OF_{i,t}$ i $DF_{i,t}$ es calculen a partir dels residus $G_i - \lambda_i$, però λ_i depèn dels paràmetres θ del GLM, que s'estimen a partir dels ràntings. Aquesta circularitat impedeix l'estimació directa dels dos conjunts de paràmetres de manera simultània.

Per resoldre-la, s'implementa un algorisme iteratiu que alterna entre l'actualització dels ràntings i l'estimació dels paràmetres del GLM, de manera anàloga al procediment EM:

1. **Inicialització:** Com que encara no existeix cap conjunt de paràmetres θ , els gols esperats s'aproximen amb les mitjanes globals: $\hat{G}_1 = \bar{G}_1$ i $\hat{G}_2 = \bar{G}_2$.
2. **Simulació inicial:** Es fixen $OF_i = DF_i = 0$ i $\Gamma_C = 0 \forall i, C$. i es simula tot l'historial de partits utilitzant $\hat{G}_1$ i $\hat{G}_2$ com a gols esperats constants, obtenint les primeres seqüències de ràntings $\{OF_{i,t}\}$, $\{DF_{i,t}\}$ i $\{\Gamma_{C,t}\}$.
3. **Pas 3:** Donats els ràntings del pas anterior, s'ajusta el GLM per màxima versemblança, obtenint $\theta^{(r)}$.
4. **Pas 4** Donats els paràmetres $\theta^{(r)}$, es re-simula tot l'historial de partits (fixant els ràntings a 0 de nou), ara amb els gols esperats calculats pel GLM ($\lambda_i = \exp(\mathbf{x}_i^\top \theta^{(r)})$), obtenint ràntings actualitzats.
5. **Iteració:** Es repeteixen els passos 3 i 4 fins que la variació en els paràmetres sigui inferior a un llindar ε :

$$\Delta^{(r)} = \max_j \left| \theta_j^{(r)} - \theta_j^{(r-1)} \right| < \varepsilon$$

4 Validació del model

L'avaluació d'un model predictiu probabilístic és diferent a l'avaluació d'un classificador convencional. No es mesura el nombre prediccions correctes, sinó la qualitat de les probabilitats que el model assigna als diferents resultats. Una bona predicció no és la que assigna probabilitat 1 al resultat correcte, sinó la que assigna probabilitats que reflecteixen fidelment la freqüència real d'aquests resultats.

Aquesta secció presenta l'estratègia de validació temporal adoptada (4.1), les mètriques implementades (4.2), la comparativa amb models de referència (4.3), l'anàlisi de convergència del procediment d'estimació (4.4) i la interpretació dels coeficients estimats (4.5).

4.1 Estratègia de validació temporal

Com s'ha especificat durant el treball, el conjunt de dades presenta una estructura temporal, cal entrenar un model fins una data específica i validar amb dades amb les quals el model no s'ha entrenat. Per evitar aquest *data leakage*, definim els següents conjunts:

- **Conjunt d'entrenament:** partits del període 2000–2022.
- **Conjunt de validació:** partits del període 2023–2026.

Tant a l'hora d'entrenar com de validar, les dades han d'estar ordenades per data, per la naturalesa dinàmica dels rànings.

Tots els paràmetres del model $(\alpha, \beta_1, \beta_2, \theta, \gamma)$ i els hiperparàmetres s'estimen exclusivament amb dades del conjunt d'entrenament.

Definim la següent notació, per a un partit i , denotem:

- $\hat{\mathbf{p}}_i = (\hat{p}_{i,1}, \hat{p}_{i,2}, \hat{p}_{i,3}) \in [0, 1]^3$ el vector de probabilitats predites, amb $\sum_k \hat{p}_{ik} = 1$.
- $\mathbf{o}_i = (o_{i,1}, o_{i,2}, o_{i,3}) \in \{0, 1\}^3$ el vector indicador del resultat real (victòria local es representaria com $(1, 0, 0)$).
- $K = 3$ classes ordenades: $k = 1$ (victòria local), $k = 2$ (empat), $k = 3$ (victòria visitant).
- N el nombre de partits del conjunt de validació.

4.2 Mètriques de calibració probabilística

Cap mètrica individual captura tots els aspectes de la qualitat d'una predicció probabilística. Aleshores, per dur a terme la validació d'aquest model es defineixen les següents mètriques.

4.2.1 Brier Score

El Brier Score [8] mesura l'error quadràtic mitjà entre probabilitats predites i resultats observats:

$$BS = \frac{1}{N} \sum_{i=1}^N \sum_{k=1}^K (\hat{p}_{ik} - o_{ik})^2 \quad (3)$$

Com podem observar, el model perfecte ($\hat{p}_i = \mathbf{o}_i \forall i$) seria un $BS = 0$. Aleshores, mentre més baix sigui el valor, major és l'exactitud del model.

4.2.2 Log-loss

El log-loss o pèrdua de versemblança negativa, és:

$$LL = -\frac{1}{N} \sum_{i=1}^N \sum_{k=1}^K o_{ik} \log \hat{p}_{ik} \quad (4)$$

Com que o_i és un vector *one-hot*, la suma interna es redueix a un sol terme corresponent a la classe real $y_i \in \{1, 2, 3\}$:

$$LL = -\frac{1}{N} \sum_{i=1}^N \log \hat{p}_{i, y_i}$$

En el cas d'una predicció errònia, on el model assigna probabilitat 0 al resultat, provocaria $LL \rightarrow +\infty$. Minimitzar aquesta funció de pèrdua és equivalent a maximitzar la versemblança del model, funció objectiu del GLM Poisson per a l'estimació dels coeficients (Secció 3.3.5).

4.2.3 Ranked Probability Score

El Brier Score i el log-loss assignen el mateix cost a predir empat quan guanya el local que a predir victòria visitant quan guanya el local. Però els tres resultats possibles en futbol són ordinals (victòria local < empat < victòria visitant), i una errada de victòria local quan victòria visitant és pitjor que una errada de empat quan victòria visitant.

El *Ranked Probability Score* [9] captura aquesta ordinalitat treballant amb les distribucions cumulatives:

$$RPS = \frac{1}{N(K-1)} \sum_{i=1}^N \sum_{k=1}^{K-1} \left(\sum_{j=1}^k \hat{p}_{ij} - \sum_{j=1}^k o_{ij} \right)^2 \quad (5)$$

Per $K = 3$, l'expressió per a un sol partit es desenvolupa:

$$RPS_i = \frac{1}{2} \left[(\hat{p}_{i,1} - o_{i,1})^2 + (\hat{p}_{i,1} + \hat{p}_{i,2} - o_{i,1} - o_{i,2})^2 \right]$$

Aquesta funció és la mètrica de referència a la literatura de pronòstic esportiu [10].

4.2.4 Reliability diagram i Expected Calibration Error

Una predicció probabilística té dos atributs independents que cal avaluar per separat. D'una banda, la calibració: si el model estima un 65% de probabilitat de victòria local, aquest resultat ha de produir-se aproximadament el 65% de les vegades en partits amb condicions similars. De l'altra, la discriminació: el model ha d'assignar probabilitats diferents a partits diferents, en lloc de quedar-se sempre a prop de la mitjana global.

Aquests dos atributs poden manifestar-se de manera independent. Un model pot estar perfectament calibrat sense ser discriminatiu, com és el cas del model que assigna sempre les freqüències marginals del conjunt d'entrenament: la seva calibració mitjana és trivialment alta perquè no s'arrisca mai. Pel contrari, un model pot ser molt discriminatiu però mal calibrat si assigna probabilitats extremes (90%, 10%) que no es corresponen amb les freqüències observades. Les regles de puntuació pròpies introduïdes anteriorment (BS, LL, RPS) capturen una barreja d'aquests dos aspectes, però no permeten distingir-los. Per això s'introdueix un diagnòstic específic de calibració.

El *reliability diagram* és la representació visual estàndard d'aquest diagnòstic. Per a cada classe $k \in \{1, 2, 3\}$, l'interval $[0, 1]$ es divideix en B bins consecutius. Per a cada bin b , es calcula la mitjana de les probabilitats predites caigudes al bin, i la freqüència empírica observada en aquests mateixos partits. El gràfic representa aquesta probabilitat predita contra la freqüència observada per a cada bin, juntament amb la diagonal $y = x$.

Un model perfectament calibrat té tots els punts sobre aquesta diagonal: les probabilitats predites coincideixen amb les freqüències observades. Les desviacions cap amunt indiquen que el model *subestima* les probabilitats reals, mentre que les desviacions cap avall indiquen *sobreestimació*.

Per obtenir una mesura numèrica de la calibració global, a més del diagrama que es mostrarà, es defineix l'*Expected Calibration Error* [11] com la mitjana ponderada de les desviacions absolutes entre $\bar{p}_b^{(k)}$ (probabilitats predites) i $\bar{o}_b^{(k)}$ (freqüències observades),

$$\text{ECE}_k = \sum_{b=1}^B \frac{n_b}{N} \left| \bar{p}_b^{(k)} - \bar{o}_b^{(k)} \right|. \quad (6)$$

Aquesta magnitud quantifica la desviació mitjana entre les probabilitats del model i la realitat empírica, ponderada pel nombre d'observacions de cada bin. Valors inferiors a 0.05 es consideren indicatius d'un bon calibratge, mentre que valors superiors a 0.10 indiquen calibratge deficient. Cal tenir en compte que, un model pot obtenir un valor ECE molt baix, però no aportar capacitat predictiva, com veurem a la Secció 4.3. Això motiva l'ús combinat de totes les mètriques definides, ja que només la combinació de calibratge i discriminació permet caracteritzar la qualitat global d'un model probabilístic.

4.3 Comparativa amb models de referència

Per a avaluar el rendiment del model proposat, es comparen les seves mètriques amb tres models de complexitat creixent:

- **Model 1 – Constants:** Es prediu sempre la freqüència marginal del conjunt d'entrenament: $\hat{\mathbf{p}}_i = (\bar{f}_H, \bar{f}_D, \bar{f}_A)$, on $\bar{f}_H, \bar{f}_D, \bar{f}_A$ són les freqüències empíriques de victòries locals, empats i victòries visitants. Aquest model no incorpora cap informació del partit concret.
- **Model 2 – Poisson amb λ constant:** Es modelitza el nombre de gols com a Poisson amb mitjanes globals: $\lambda_1 = \bar{g}_H, \lambda_2 = \bar{g}_A$, on $\bar{g}_H, \bar{g}_A$ són la mitjana de gols marcats pels locals i visitants al conjunt d'entrenament. Els tres resultats es computen com s'indica a la Secció 3.3.1.
- **Model 3 – ELO clàssic:** Cada selecció disposa d'un únic ràting escalar R_i que s'actualitza amb la fórmula estàndard $R_{i,t+1} = R_{i,t} + K(S_i - E_i)$, on $S_i \in \{0, 0.5, 1\}$ és el resultat real i E_i la probabilitat esperada.

La Taula 3 presenta els valors de les mètriques sobre el conjunt de validació.

Model	BS	LL	RPS	ECE
Constants	0.6384	1.0573	0.2297	0.0146
Poisson λ constant	0.6415	1.0625	0.2312	0.0332
ELO clàssic	0.5360	0.9109	0.1785	0.0472
ELO-Poisson (proposat)	0.5077	0.8647	0.1671	0.0411

Taula 3: Comparativa de mètriques predictives entre el model proposat i tres baselines de complexitat creixent. Avaluats sobre el conjunt 2023–2026.


Els models 1 i 2 presenten resultats pràcticament idèntics. Modelar la distribució de gols amb una Poisson sense informació específica per equip aporta valor predictiu marginal.

Si seguim comparant amb el model 3, observem que la introducció d'un ràting dinàmic per equip constitueix el salt qualitatiu més gran: redueix el Brier Score un 16%, el log-loss un 14% i el RPS un 23% respecte el model 2. Aquest resultat confirma que el ràting dinàmic és el component més rellevant del modelatge en futbol internacional.

Finalment, el model proposat aporta millores consistents addicionals respecte l'ELO clàssic: 5.3% en BS, 5.1% en LL, 6.4% en RPS, i 12.9% en ECE. La millora és menor que l'anterior, però sistemàtica en totes les mètriques, i particularment marcada en la calibració.

Amb aquests resultats podem il·lustrar la diferència entre calibració i discriminació. Com es pot observar, el model 1 obté el millor ECE, inferior al model proposat, ja que el model Constants prediu sempre les freqüències marginals del conjunt d'entrenament (les del conjunt de validació són properes), aleshores, el model està ben calibrat; però no discrimina entre partits, fet que es reflecteix amb les altres mètriques.

La Figura 3 mostra el reliability diagram del model proposat per a cadascun dels tres resultats. La calibració és bona en totes tres classes ($ECE < 0.06$), amb l'empat ($ECE = 0.028$) com a classe millor calibrada. La victòria visitant presenta una calibració lleugerament inferior ($ECE = 0.059$), suggerint que aquesta és la classe que el model captura amb més dificultat. Aquest patró és coherent amb les particularitats del futbol, on les victòries visitants són sovint més difícils de predir per la seva major variabilitat.






Figura 3: Reliability Diagrams individuals per a cadascun dels tres resultats possibles en el conjunt de validació (2023–2026).

Per a contextualitzar el rendiment del model més enllà de la comparativa amb els models definits, és útil comparar-lo amb models de referència publicats que aborden el mateix problema. Un dels més rellevants és Dolores [12], que combina ràtings dinàmics amb xarxes bayesianes i obté un RPS de 0.211 sobre 206 partits de 26 lligues de clubs.

El RPS del model proposat (0.167) és inferior al de Dolores, però aquesta comparació cal interpretar-la amb prudència: Dolores opera sobre partits de clubs en lligues regulars, mentre que el present treball es centra en futbol internacional de seleccions, on la dispersió de força entre equips és substancialment major (Espanya – San Marino vs. Barcelona – Sevilla). Aquesta asimetria fa que els partits internacionals siguin, en mitjana, més predictibles que els de clubs, fet que afavoreix els RPS més baixos. Per tant, la comparació no demostra una superioritat del model proposat, sinó la seva capacitat d'extreure correctament la informació estructural del context al qual s'aplica.

4.4 Anàlisi de convergència de l'algorisme iteratiu

Com hem vist a la Secció 3.3.5, l'estimació dels paràmetres del GLM i dels ELOs s'ha realitzat amb l'algorisme presentat. Hem definit la màxima variació per cada pas, com la màxima variació dels paràmetres entre una iteració i la següent:

$$\Delta^{(r)} = \max_j \left| \theta_j^{(r)} - \theta_j^{(r-1)} \right|.$$

S'estableix el criteri de convergència si $\Delta^{(r)} < 10^{-4}$ amb un màxim de 30 iteracions:




Figura 4: Evolució de la màxima variació dels coeficients $\Delta^{(r)}$ al llarg de les iteracions de l'algorisme iteratiu.

La Figura 4 mostra una trajectòria asimptòtica i monòtonament decreixent. Les primeres iteracions presenten variacions grans, conseqüència del ràpid ajust inicial entre els ràntings i el model; després, la pendent s'aplana progressivament. El criteri de convergència, no s'arriba a assolir en les 30 iteracions, la magnitud de la última variació ($\Delta^{(30)} = 0.0011$) és superior al del criteri, però, suficientment baix per poder determinar que els coeficients han convergit.

4.5 Interpretació dels coeficients estimats

La següent taula presenta les estimacions finals dels coeficients del GLM, els seus errors estàndard, els valors del test de Wald i els p-valors corresponents.

Paràmetre	Estimació	Error estàndard	z	p-valor
α	0.1527	0.0054	28.30	< 0.0001
β_1	0.0676	0.0009	72.80	< 0.0001
β_2	-0.0987	0.0011	-88.57	< 0.0001
θ	0.4372	0.0092	47.34	< 0.0001
γ	0.0211	0.0101	2.08	0.0371

Taula 4: Coeficients estimats del GLM Poisson per al model ELO-Poisson. Errors estàndard, test de Wald amb significança bilateral i p-valor.

La Taula 4 presenta, per a cada coeficient, l'estimació puntual, el seu error estàndard i el resultat del test de Wald (z i p -valor), que contrasta la hipòtesi nul·la que el coeficient és igual a zero. Quatre dels cinc paràmetres (α , β_1 , β_2 , θ) presenten p -valors inferiors a 10^{-4} i $z > 28$, de manera que podem afirmar la seva significància. El cinquè, l'avantatge de camp γ , presenta en canvi una significació marginal ($z = 2.08$, $p = 0.037$).

Abans d'interpretar els coeficients, convé fer una aclaració sobre aquesta inferència. Els errors estàndard provenen de l'ajust del GLM, el qual està condicionat als ràntings, que el model tracta com a valors fixes i coneguts. Ara bé, els ràntings no són dades observades, sinó que s'han estimat a partir dels mateixos partits. Per tant, incorporen una incertesa pròpia que l'error estàndard del GLM no recull, de manera que els errors estàndard reportats són, possiblement, optimistes, és a dir, els valors reals

dels errors estàndard serien superiors i els p -valors, més conservadors.

Ara si, interpretació dels coeficients:

- α (**intercept**): Determina el nombre esperat de gols d'un partit quan les variables són 0 (ràtings ofensiu i defensiu nuls, joc en camp neutre i confederacions amb el mateix Γ_C). El valor estimat $\hat{\alpha} = 0.1527$ correspon a $e^{\hat{\alpha}} \approx 1.17$ gols esperats per equip.
- β_1 (**ràting ofensiu**): Coeficient associat al ràting ofensiu propi. El valor estimat $\hat{\beta}_1 = 0.0676$ és positiu i se situa molt lluny de zero ($z = 72.8$), de manera que confirma que la capacitat ofensiva contribueix positivament als gols esperats.
- β_2 (**ràting defensiu rival**): Coeficient associat al ràting defensiu del rival. El valor estimat $\hat{\beta}_2 = -0.0987$ és negatiu i és el coeficient que se situa més lluny de zero de tot el model ($z = -88.6$). Que sigui negatiu és coherent amb el seu paper, mentre β_1 augmenta els gols esperats en funció de la capacitat ofensiva pròpia, β_2 els redueix en funció de la capacitat defensiva del rival.
- θ (**diferència de nivell de confederació**): Recull l'efecte de la diferència de ràtings de confederació de les dues seleccions, $\Gamma_{C_1} - \Gamma_{C_2}$. El valor estimat $\hat{\theta} = 0.4372$ és positiu i clarament allunyat de zero ($z = 47.3$), fet que confirma que el nivell global de la confederació aporta capacitat predictiva més enllà dels ràtings individuals de les seleccions.
- γ (**avantatge de camp**): Increment del nombre esperat de gols per a l'equip local quan el partit no es disputa en camp neutre ($H = 1$, $A = -1$). És, amb diferència, el coeficient que menys informació aporta del model: la seva $z = 2.08$ el situa just per sobre del llindar de significació ($p = 0.037$). A més, la seva magnitud és petita ($e^{\hat{\gamma}} \approx 1.02$): el model atribueix a la localitat un efecte modest sobre els gols esperats.

Per finalitzar aquesta validació, concloem amb les següents afirmacions sobre el nostre model:

1. **El model té una bona capacitat predecitiva.**

Els resultats obtinguts, $BS = 0.508$, $LL = 0.865$ i $RPS = 0.167$, es troben en línia amb els estàndards reportats per la literatura acadèmica en models de pronòstic futbolístic [12].

2. **El model té una calibració adequada.**

Un ECE mitjà de 0.041 és un valor per un model ben calibrat d'acord amb la literatura de referència en classificació probabilística [11].

3. **El model millora el model ELO clàssic.**

Amb unes millores del 5–6% en totes les mètriques, i del 13% en calibració, on quatre dels cinc coeficients són clarament significatius.

Després de concloure que el model és vàlid, en la següent secció l'aplicarem per simular la Copa del Món 2026 i estimar les probabilitats de guanyar el torneig.

5 Simulació de la Copa del Món 2026

Aquesta secció descriu com s'aplica el model per a estimar les probabilitats de cada selecció en la Copa del Món 2026. El procediment combina dues idees: una simulació que replica el format del torneig partit a partit, i el mètode de Monte Carlo, que executa la simulació 100000 vegades per estimar les probabilitats com a freqüències.

5.1 Estructura del torneig

La Copa del Món 2026 estrena un nou format, ampliant de 32 seleccions a 48 (distribuïdes en 12 grups de 4 equips) i afegint una nova fase final prèvia als vuitens de final, els setzens, passant dels 64 partits que es van disputar a l'últim Mundial a 104.

Cada equip disputa tres partits dins del seu grup, amb el sistema clàssic de puntuació (3 punts per victòria, 1 per empat, 0 per derrota). Els dos primers classificats de cada grup avancen directament a la fase eliminatòria, juntament amb els 8 millors tercers classificats. En total, 32 seleccions accedeixen a la fase eliminatòria.

Aquesta fase s'inicia amb els setzens de final (32 seleccions) i continua com un torneig d'eliminació normal: vuitens (16), quarts (8), semifinals (4), i finalment la final. Com es tracta d'un Mundial amb tres seus (Mèxic, Estats Units i Canadà), les respectives seleccions juguen com anfitriones la fase de grups, en canvi, per la fase final del torneig, els partits es jugaran als Estats Units, excepte les dues primeres rondes eliminatòries (setzens i vuitens) on alguns partits es disputaran a Mèxic i Canadà també. Després de la fase de grups, en cas d'empat es resol el partit en una pròrroga, i en cas de continuar empatat, penals.

5.2 Simulació d'un partit individual

Per a cada partit, donats els ràtings OF_i , DF_i i Γ_{C_i} de cada equip en el moment i la variable de la localia, es calcula mitjançant el model entrenat els gols esperats de cada equip, λ_1 i λ_2 . Seguidament, es generen els gols mitjançant dues variables Poisson independents: $G_1 \sim \text{Poisson}(\lambda_1)$ i $G_2 \sim \text{Poisson}(\lambda_2)$. El resultat del partit ve donat pel parell (G_1, G_2) .

Com s'ha explicat, durant els partits de rondes eliminatòries no poden finalitzar en empat. Per tant, els partits en què $G_1 = G_2$ es resolen amb una probabilitat del 50% per a cada equip de passar de ronda.

Després de cada partit, s'actualitzen els ràtings de les seleccions implicades segons les regles definides a la Secció 3.3.2, permetent capturar la dinàmica dels equips al llarg del torneig.

Per a demostrar que els resultats generats són aleatoris però seguint la distribució definida, a les Figures 5 i 6, es pot observar, en primer lloc, la distribució dels gols de cada equip en el partit inaugural (Mèxic vs Sud-Àfrica) i també les freqüències dels gols de cada selecció després de simular el partit 100000 vegades.




Figura 5: Distribució de gols pel partit Mèxic vs Sud-Àfrica




Figura 6: Freqüències de gols pel partit Mèxic vs Sud-Àfrica després de simular el partit 100000 vegades

5.3 Simulació d'una edició del torneig

Una simulació completa del Mundial 2026 consisteix en la simulació seqüencial de tots els partits del torneig:

Pas 1 (fase de grups): Es simulen els partits de la fase de grups. Per a continuar l'ordre definit per la FIFA, es simula en primer lloc la primera jornada, després la segona, i per finalitzar la tercera. Es calculen els punts de cada selecció i es construeixen les taules de classificació de cada grup, en cas d'igualtat de punts se segueix els criteris definits per la FIFA: diferència de gols i gols a favor. Es classifiquen els dos primers de cada grup i els vuit millors tercers, ordenats per punts, diferència de gols i gols a favor.

Pas 2 (fase eliminatòria): Es genera el quadre oficial (Secció C), i es simulen ronda a ronda, fins obtenir el guanyador.

Pas 3 (registre): Per a cada selecció es registra la fase final on ha quedat eliminada (fase de grups, setzens, vuitens, quarts, semifinals, finalista, campió). Aquest registre constitueix el resultat d'una simulació individual.

5.4 Mètode de Monte Carlo

Una sola simulació del torneig produeix un resultat puntual. Per estimar les probabilitats per a cada selecció i cada fase, repetim el procediment un nombre elevat de vegades i calculem les freqüències empíriques.

Segui N_{sim} el nombre total de simulacions del torneig. Per a cada selecció i i cada fase ϕ

$$\phi \in \{\text{grups, setzens, vuitens, quarts, semifinal, final, campió}\}$$

, la probabilitat estimada s'obté com:

$$\hat{P}(\text{selecció } i \text{ assoleix } \phi) = \frac{1}{N_{\text{sim}}} \sum_{s=1}^{N_{\text{sim}}} \mathbb{1}[\text{en la simulació } s, \text{ la selecció } i \text{ assoleix } \phi]$$

on $\mathbb{1}[\cdot]$ és la funció que indica si la selecció i assoleix ϕ i $N_{\text{sim}} = 100000$.

6 Resultats

A partir de la simulació Monte Carlo descrita a la Secció 5, amb $N_{\text{sim}} = 100\,000$ execucions independents del torneig, s'obtenen les probabilitats que cada selecció arribi a cadascuna de les fases de la Copa del Món 2026. Aquesta secció presenta i discuteix els resultats en quatre blocs: les probabilitats per fase del torneig (6.1), l'anàlisi per confederació (6.2), l'evolució dels rànquings (6.3) i la comparativa amb les probabilitats implícites del mercat d'apostes (6.4).

6.1 Probabilitats per fase del torneig

La Taula 5 presenta, per a les 20 seleccions amb major probabilitat de guanyar el Mundial 2026, la probabilitat d'arribar a cadascuna de les fases del torneig. Els resultats estan ordenats de major a menor probabilitat de campió.

Selecció	Setzens	Vuitens	Quarts	Semis	Final	Campió
Espanya	99.71	75.83	54.26	41.36	27.75	17.64
Anglaterra	99.10	76.94	58.73	37.51	23.02	13.14
Brasil	99.41	69.67	49.86	31.49	18.67	10.83
França	98.02	76.11	47.92	31.41	17.57	9.50
Argentina	98.64	61.69	46.09	28.72	16.53	9.24
Portugal	98.35	73.71	48.61	30.76	17.18	8.87
Alemanya	99.08	74.27	41.63	25.76	12.79	6.20
Països Baixos	93.50	54.74	41.04	21.69	10.72	5.07
Bèlgica	97.17	69.73	48.22	21.43	10.62	4.68
Colòmbia	94.24	55.25	28.10	14.88	6.78	2.94
Marroc	93.63	43.41	26.00	11.16	4.57	1.69
Croàcia	92.89	51.66	24.08	11.56	4.78	1.68
Suïssa	97.74	65.78	27.75	12.39	4.80	1.61
Uruguai	92.83	40.68	22.91	10.25	4.01	1.43
Noruega	87.44	49.71	21.50	9.67	3.61	1.12
Equador	89.21	42.49	16.23	6.89	2.45	0.80
Japó	72.94	27.68	14.99	5.19	1.83	0.59
Senegal	74.97	33.51	11.94	4.48	1.46	0.46
Àustria	83.76	28.40	12.65	5.02	1.57	0.43
Estats Units	74.09	34.57	12.27	3.14	0.86	0.22

Taula 5: Probabilitats (en %), de les 20 seleccions amb major probabilitat de guanyar, que cada selecció arribi a cada fase de la Copa del Món 2026, segons el model proposat i la simulació realitzada.

Amb aquestes distribucions identifiquem els següents tres nivells de seleccions favorites:

Favorites: Definim com a les favorites, les seleccions que $P_{\text{campió}} > 10\%$, en aquest nivell n'hi ha tres seleccions: Espanya, Anglaterra i Brasil, on entre les 3 es concentra el 40% de les victòries del torneig. Espanya és l'equip amb més probabilitat de guanyar el torneig amb un 17,64%.

Aspirants: Definim com a les aspirants, les seleccions que $5\% < P_{\text{campió}} < 10\%$, aquest nivell està format per França, Argentina, Portugal, Alemanya i Països Baixos.

Possibles sorpreses Definim com a possibles sorpreses, les seleccions que $P_{\text{campió}} < 5\%$, on destaquen Colòmbia, Marroc i Croàcia. Com podem observar, el Marroc va ser la sorpresa de la última edició, arribant a les semifinals del torneig, sent així la primera vegada que una selecció africana arribava a aquesta ronda del torneig. També, Croàcia va ser la sorpresa de la Copa del Món 2018, arribant a la final, i fent una molt bona actuació en aquest últim, també arribant a semifinals.

Finalment, és destacable que cap selecció presenta una probabilitat de campionat superior al 18%.

6.2 Anàlisi per confederació

La Taula 6 mostra la millor selecció de cada confederació segons probabilitat de campionat.

Confederació	Γ_C	Selecció líder	$P_{\text{campió}}$
UEFA	1.16	Espanya	17.64
CONMEBOL	1.95	Brasil	10.83
CAF	0.29	Marroc	1.69
AFC	-0.68	Japó	0.59
CONCACAF	-0.88	Estats Units	0.22
OFC	-1.84	Nova Zelanda	0.00

Taula 6: Selecció líder de cada confederació segons probabilitat de campionat al Mundial 2026.

Els valors de Γ_C revelen una jerarquia clara entre confederacions. CONMEBOL i UEFA ocupen els dos primers llocs amb valors significativament superiors a la resta. La CAF se situa lleugerament per sobre de zero, en canvi, AFC, CONCACAF i OFC presenten valors negatius, reflectint el seu rendiment històricament inferior en partits contra seleccions d'altres confederacions.

Tanmateix, els valors de Γ_C no impliquen superioritat per guanyar el torneig. Si observem UEFA i CONMEBOL, tot i que CONMEBOL presenta un Γ_C superior, Espanya té més probabilitats de guanyar el torneig que Brasil.

Una possible explicació és que el ràting Γ_C captura el nivell mitjà d'una confederació, i CONMEBOL està formada per 10 seleccions, totes amb un nivell competitiu més homogeni que la UEFA, ja que la confederació europea consta de 55 seleccions amb una gran diferència de nivell, des de les principals potències, com les que apareixen al top de la Taula 5, fins a seleccions de menor nivell com Andorra o San Marino, moderant el valor de Γ_C .

6.3 Evolució dels ràtings

A continuació, les Figures 7 i 8 es pot observar la evolució dels ràtings a les confederacions UEFA i CONMEBOL.




Figura 7: Evolució dels ràtings ofensius i defensius a la UEFA




Figura 8: Evolució dels ràtings ofensius i defensius a la CONMEBOL

S'han destacat els ràtings de les principals seleccions de cada confederació. Segons el model, Brasil ha dominat clarament la CONMEBOL des de l'any 2000, mentre que la UEFA mostra una competència més distribuïda entre les millors seleccions de la confederació.

6.4 Comparativa amb el mercat d'apostes

Una manera natural d'avaluar l'aportació pràctica del model és comparar les probabilitats predites amb les probabilitats donades pel mercat d'apostes. Les quotes de cases d'apostes incorporen no només informació estadística històrica sinó també el flux de capital del mercat, expectatives qualitatives i informació en temps real sobre les seleccions (lesions, forma recent, dinàmica del vestidor, ...). Constitueixen, per tant, una referència externa amb la qual contrastar les prediccions d'un model purament probabilístic.

6.4.1 Conversió de quotes a probabilitats

Les quotes decimals de Bet365 es converteixen a probabilitats implícites mitjançant la inversió simple $p_i = 1/o_i$, on o_i és la quota decimal per a la selecció i . Aquestes probabilitats implícites no sumen exactament 1 a causa del marge de la casa d'apostes.

6.4.2 Comparativa

Selecció	Model	Bet365	Diferència
Espanya	17.64	18.18	-0.54
Anglaterra	13.14	12.50	+0.64
Brasil	10.83	11.11	-0.28
França	9.50	16.66	-7.16
Argentina	9.24	10.00	-0.76
Portugal	8.87	11.76	-2.89
Alemanya	6.20	6.66	-0.46
Països Baixos	5.07	4.76	+0.31
Bèlgica	4.68	2.94	+1.74
Colòmbia	2.94	2.94	0.00

Taula 7: Comparativa entre les probabilitats de campionat segons el model proposat i les probabilitats implícites de Bet365. Es mostren les 10 seleccions amb major probabilitat segons el model.

6.4.3 Interpretació

Observant la Taula 7, podem destacar que en sis dels deu casos la diferència és inferior a un 1%, fet que reforça la idea que el model captura adequadament la jerarquia esportiva reconeguda pel mercat. Tanmateix, hi ha tres casos que mereixen discussió particular:

1. **Discrepància gran amb França (-7.16).** La diferència més gran de la taula es produeix amb França, a qui el model assigna una probabilitat de campionat substancialment inferior a la del mercat (9.50% enfront de 16.66%). El mercat la situa al nivell d'Espanya i Anglaterra, mentre que el model la posiciona sota aquestes. Aquesta diferència pot reflectir factors que el model no incorpora, ja que el model tracta cada selecció com un agent, sense considerar la qualitat individual dels jugadors.
2. **Discrepància moderada amb Portugal (-2.89).** Portugal és l'altra selecció on el mercat es mostra més optimista que el model. Un dels possibles motius és també la qualitat individual dels jugadors.
3. **Discrepància inversa amb Bèlgica (+1.74).** En el sentit contrari, el model assigna a Bèlgica una probabilitat de campionat superior a la del mercat (4.68% enfront de 2.94%). El mercat sembla penalitzar Bèlgica, probablement per la sensació del final de la generació daurada.

7 Conclusions

Aquest treball ha desenvolupat un model probabilístic per al futbol internacional de seleccions, amb l'objectiu d'estimar les probabilitats de cada selecció en la Copa del Món 2026 mitjançant simulació de Monte Carlo. El model proposat estén el sistema ELO clàssic de tres maneres fonamentals: descompon la força de cada selecció en una component ofensiva i una de defensiva, incorpora un ràting de confederació amb propagació intercontinental, i estima els seus paràmetres mitjançant un algorisme iteratiu inspirat en el procediment EM.

Els objectius plantejats a la introducció s'han assolit satisfactòriament. Pel que fa al disseny del model, la formulació ELO-Poisson amb ràtings ofensius i defensius soluciona limitacions identificades del sistema ELO clàssic en el context futbolístic (integra la magnitud dels resultats, distingeix capacitat ofensiva i defensiva, modelitza l'avantatge de camp i calibra el nivell relatiu de cada confederació) i, a més, el sistema té una capacitat de la qual l'ELO clàssic no disposa: l'emissió de distribucions de gols, amb les quals es poden generar resultats.

Pel que fa a la validació, el model assoleix un Brier Score de 0.508, un log-loss de 0.865 i un RPS de 0.167 sobre el conjunt de validació, valors que se situen en línia amb els reportats a la literatura de pronòstic futbolístic, si bé les comparacions directes entre estudis s'han d'interpretar amb prudència per les diferències de context (futbol de clubs i de seleccions). La comparativa amb tres models de complexitat creixent (constants, Poisson amb λ constant i ELO clàssic) mostra que el model proposat millora de manera consistent en totes les mètriques: la introducció d'un ràting dinàmic per equip constitueix la millora estructural més important (−16% en Brier Score respecte del model Poisson), i la descomposició ofensiva-defensiva amb ràting de confederació hi afegeix una millora addicional del 5–6% sobre l'ELO clàssic. D'aquesta comparativa cal destacar, que l'ELO clàssic és ja un model de base sòlid, aleshores, la contribució del model proposat no millora significativament la part probabilística sino que aporta la capacitat de generar resultats. Quant a la inferència sobre els coeficients, els quatre paràmetres estructurals (α , β_1 , β_2 , θ) resulten clarament significatius, mentre que l'avantatge de camp (γ) presenta una significació marginal.

Per últim, pel que fa a la simulació del Mundial, l'execució de 100.000 simulacions independents identifica Espanya (17.6%), Anglaterra (13.1%) i Brasil (10.8%) com els tres principals candidats a alçar el torneig. La comparativa amb les probabilitats implícites de Bet365 mostra una alineació notable per a la majoria de seleccions, amb només dues discrepàncies destacables: França i Portugal, ambdues amb una valoració més optimista per part del mercat, probablement per la qualitat individual dels seus jugadors, variable que el model no contempla.

Per concloure, la descomposició en components ofensiva i defensiva permet caracteritzar l'estil de joc de cada selecció; el ràting de confederació permet comparar seleccions de confederacions diferents, i la formulació basada en gols esperats permet calcular probabilitats de resultat exacte. Aquesta riquesa interpretativa, juntament amb la naturalesa íntegrament probabilística del model, constitueix una contribució metodològica rellevant per al pronòstic futbolístic.

A Repositori de codi

Tot el codi desenvolupat per a aquest treball està disponible públicament al repositori de GitHub:

https://github.com/ssaaaam/world_cup_simulation

El repositori conté l'estructura següent:

- **data/**: Carpeta on es trobarà el conjunt de dades original i arxius creats per a la simulació del mundial.
- **src/**: implementació de les funcions principals del model. Inclou els següents scripts:
 - **elo.py**: Simulació dels rànking.
 - **model.py**: Entrenament del model GLM.
 - **convergence.py**: Algorisme EM.
 - **grid_search.py**: Optimització dels *learning rates*.
 - **groups.py**: Estructura per a la creació dels grups a la simulació.
 - **make_dataset.py**: Neteja de les dades i creació del conjunt de dades que s'utilitza durant el projecte.
 - **make_third_place_table.py**: Creació de les diferents combinacions dels millors tercers.
 - **:** Funció per seleccionar n partits random, per verificar manualment que les dades són correctes.
- **notebooks/**: tres notebooks amb tot el flux d'execució: entrenament del model, validació i simulació del torneig.
- **results/**: paràmetres estimats del model i del learning rate i resultats de les simulacions.
- **README.md**: instruccions d'instal·lació i reproducció dels resultats.
- **requirements.txt**: dependències de Python necessàries.

Per reproduir els resultats del treball, només cal clonar el repositori, instal·lar les dependències indicades a **requirements.txt** i executar els *notebooks* en ordre.

B Verificació del conjunt de dades

Per dur a terme la verificació de les dades, per comprovar que les dades del conjunt són precises, s'ha programat un arxiu (`verification.py`) que selecciona n partits aleatoris, per tal de comprovar manualment que les dades són precises.

C Generació quadre fase eliminatòria Copa del Món

Com s'ha explicat a la Secció 5.1 no només classifiquen els dos primers de cadascun dels 12 grups, sino que també els 8 millors tercers classificats. Aquesta novetat genera una dificultat addicional respecte a edicions anteriors, ja que la composició concreta del quadre eliminatori depèn de quins són exactament aquests 8 tercers, i la FIFA estableix un sistema d'assignació predeterminat per a cada combinació possible.

Concretament, hi ha $\binom{12}{8} = 495$ combinacions possibles, i cadascuna d'aquestes combinacions porta associada una assignació específica de quins tercers juguen contra quins guanyadors de grup. Aquesta assignació no es pot deduir per regla simple, sinó que respon a un quadre oficial dissenyat per la FIFA per evitar emparellaments entre seleccions del mateix grup en les primeres rondes i garantir un equilibri geogràfic. Totes les combinacions possibles es poden consultar a [13]. A continuació, primer s'explicarà com s'ha generat el quadre i després com s'ha gestionat els millors tercers.

Aleshors, primer s'ha creat un fitxer JSON amb el quadre base de la fase eliminatòria. En aquest fitxer trobem 5 classes diferents (*round_of_32*, *round_of_16*, *quarter-finals*, *semi-finals* i *final*), on per cada classe es defineixen els diferents partits: la ronda de setzens abarca els partits 73 a 88 (16 partits en total), els vuitens els partits 89 a 96 (8 partits), els quarts els partits 97 a 100 (4 partits), les semifinals els partits 101 i 102, i finalment la final el partit 104.

Cada partit es defineix com un parell d'equips. Per als setzens, els codis fan referència o bé als classificats de cada grup (1A, 2B, 1C, ...) o bé als millors tercers, codificats genèricament com "", ja que aquests valors dependran de la combinació específica de tercers donada. Per a les rondes posteriors, els codis són els identificadors dels partits previs: per exemple, el partit 89 (vuitens) enfronta el guanyador del partit 73 amb el del partit 74.

Aquesta estructura permet representar tot el quadre eliminatori sense necessitat de noms d'equip concrets, ja que aquests es resolen durant la simulació un cop coneguda la classificació de la fase de grups.

Per gestionar els 8 millors tercers, s'ha generat un segon fitxer JSON amb un diccionari que mapeja cadascuna de les 495 combinacions possibles a la seva assignació corresponent. Les claus identifiquen els 8 grups dels quals provenen els tercers classificats (per exemple, "ABCDEFGH") i els valors indiquen a quin partit dels setzens va el tercer de cada grup. Aquest diccionari s'ha construït mitjançant *scraping* d'una pàgina web que publica el quadre per a cadascuna de les combinacions possibles, evitant així haver d'introduir les 495 assignacions manualment.

D Comparació dels resultants de la simulació amb altres models

Finalment, una manera de validar el model proposat es comparant les prediccions amb les d'altres models predictius publicats sobre el mateix torneig. A diferència de la validació presentada, aquesta comparació no permet determinar quin model és més precís, sino valorar si les probabilitats estimades s'alineen amb les d'altres metodologies que aborden el mateix problema.

Per dur a terme aquesta comparació, prendrem com a referència dos models públics que estimen les probabilitats de campionat del Mundial 2026. El primer és el model de Steven Stern, professor de la Universitat Bond, que, de manera anàloga a aquest treball, simula el torneig un milió de vegades a partir d'un sistema de ràtings [14]. El segon són les prediccions publicades per El País realitzades per Kiko Llaneres [15] on com a variables pren el rànking FIFA i el valor de les plantilles.

Selecció	Model proposat	Stern	El País
Espanya	17.64	15.8	14.5
Anglaterra	13.14	11.0	9.4
Brasil	10.83	4.9	6.2
França	9.50	15.6	14.0
Argentina	9.24	15.3	13.6

Taula 8: Probabilitats de campionat (%) del model proposat enfront dels models de Stern i d'El País, per a les cinc seleccions amb major probabilitat segons el model proposat.

Els tres models coincideixen a situar Espanya com a clara favorita, si bé el model proposat hi concentra una mica més de probabilitat. A partir d'aquí, apareixen diferències, Tant Stern com El País situen França i Argentina al primer nivell de candidates, totes dues per sobre del 13%, mentre que el model proposat les relega a un segon esglao proper al 9%. En sentit invers, el model proposat es mostra clarament més optimista amb Anglaterra i, sobretot, amb Brasil.

Aquest patró és coherent amb el que ja s'observava en la comparativa amb el mercat d'apostes (Secció 6.4), el model basat exclusivament en resultats, infravalora seleccions amb un nivell de jugadors molt alt i sobrevalorant seleccions amb bons resultats objectius recent.

Referències

- [1] M. J. Maher. Modelling association football scores. *Statistica Neerlandica*, 36(3), 1982.
- [2] Arpad E. Elo. *The Rating of Chessplayers, Past and Present*. Arco Publishing, New York, 1978.
- [3] Mart J. International football results from 1872 to 2024. <https://www.kaggle.com/datasets/martj42/international-football-results-from-1872-to-2017>, 2024.
- [4] Ralph A. Bradley and Milton E. Terry. Rank analysis of incomplete block designs: I. the method of paired comparisons. *Biometrika*, 39(3/4):324–345, 1952.
- [5] Mark J. Dixon and Stuart G. Coles. Modelling association football scores and inefficiencies in the football betting market. *Journal of the Royal Statistical Society: Series C (Applied Statistics)*, 46(2):265–280, 1997.
- [6] ELO Ratings. International football club and national team ratings. <https://eloratings.net/>, 2026.
- [7] A. P. Dempster, N. M. Laird, and D. B. Rubin. Maximum likelihood from incomplete data via the EM algorithm. *Journal of the Royal Statistical Society: Series B*, 39(1):1–22, 1977.
- [8] Glenn W. Brier. Verification of forecasts expressed in terms of probability. *Monthly Weather Review*, 78(1):1–3, 1950.
- [9] Edward S. Epstein. A scoring system for probability forecasts of ranked categories. *Journal of Applied Meteorology*, 8:985–987, 1969.
- [10] Anthony C. Constantinou and Norman E. Fenton. Solving the problem of inadequate scoring rules for assessing probabilistic football forecast models. *Journal of Quantitative Analysis in Sports*, 8(1), 2012.
- [11] Chuan Guo, Geoff Pleiss, Yu Sun, and Kilian Q. Weinberger. On calibration of modern neural networks. pages 1321–1330, 2017.
- [12] Anthony C. Constantinou. Dolores: a model that predicts football match outcomes from all over the world. *Machine Learning*, 108:49–75, 2019.
- [13] FIFA. Fifa world cup 2026 regulations. https://digitalhub.fifa.com/m/636f5c9c6f29771f/original/FWC2026_regulations_EN.pdf, 2026.
- [14] Deutsche Welle. Este modelo matemático simuló el mundial un millón de veces: estos son los grandes favoritos. <https://www.dw.com/es/este-modelo-matem%C3%A1tico-simul%C3%B3-el-mundial-un-mill%C3%B3n-de-veces-estos-son-los-grandes-favoritos/a-77524844>, 2026.
- [15] El País. Quién ganará el mundial: así arrancan nuestras predicciones. <https://elpais.com/deportes/mundial-futbol/2026-06-11/quien-ganara-el-mundial-asi-arrancan-nuestras-predicciones.html>, 2026.
- [16] L. Badiella, P. Puig, C. Lago-Peñas, and M. Casals. Influence of red and yellow cards on team performance in elite soccer. *Annals of Operations Research*, 325(1):149–165, 2023.
- [17] Allan H. Murphy. A new vector partition of the probability score. *Journal of Applied Meteorology*, 12:595–600, 1973.
- [18] Tilmann Gneiting and Adrian E. Raftery. Strictly proper scoring rules, prediction, and estimation. *Journal of the American Statistical Association*, 102(477):359–378, 2007.
- [19] Lars Magnus Hvattum and Halvard Arntzen. Using elo ratings for match result prediction in association football. *International Journal of Forecasting*, 26(3):460–470, 2010.

- [20] Edward Wheatcroft. Evaluating probabilistic forecasts of football matches: the case against the ranked probability score. *Journal of Quantitative Analysis in Sports*, 17(4):273–287, 2021.
- [21] Leonardo Egidi, Francesco Pauli, and Nicola Torelli. Combining historical data and bookmakers' odds in modelling football scores. *Statistical Modelling*, 18(5-6):436–459, 2018.
- [22] Richard Pollard. Home advantage in football: A current review of an unsolved puzzle. *The Open Sports Sciences Journal*, 1:12–14, 2008.